福州理工学院
FUZHOU INSTITUTE OF TECHNOLOGY

本科生毕业论文（设计）

开 题 报 告

题　　目：基于本地大模型的智能 AI 陪伴聊天系统的设计与实现

姓　　名：郭耀彬

学　　号：2301132013

学　　院：计算与信息科学学院

专　　业：计算机科学与技术

年　　级：2023 级

指导教师签名：×××

时　　间：2026 年 10 月 11 日

批注 [1]: 专升本专业在专业名称后面加上（专升本）

批注 [2]: 普本为 2023 级，专升本为 2025 级

批注 [3]: 电子版提供电子签；纸质版手签;有第二指导老师的加第二指导老师签名

论文题目：基于本地大模型的智能 AI 陪伴聊天系统的设计与实现

1. 选题背景及研究的目的和意义

1.1 选题背景

大语言模型自 2017 年 Transformer 架构提出以来发展迅速，以 ChatGPT 为代表的生成式大模型在自然语言理解与生成方面表现出强大能力，已广泛应用于智能问答、内容创作、代码生成等领域。与此同时，人们对人工智能的需求正从“能回答问题”的工具型交互，逐步转向“能提供情感支持与长期陪伴”的关系型交互，Character.AI、星野等 AI 角色扮演与陪伴类产品快速兴起，受到大量年轻用户欢迎。然而，现有方案仍存在明显不足：一是通用大模型助手缺乏稳定的人格设定与情感连续性，难以形成长期陪伴关系；二是云端 API 服务存在数据隐私泄漏风险与持续调用成本，用户对话数据无法完全自主掌控；三是单一终端产品难以满足用户在电脑、手机等多场景下的使用需求。在此背景下，设计并实现一个基于本地大模型的智能 AI 陪伴聊天系统，具有现实必要性与可行性。

近年来，随着大语言模型技术的快速演进，智能对话应用已由工具型问答向情感陪伴、角色扮演等多元化场景拓展，用户对可长期陪伴、人格稳定且尊重隐私的 AI 伙伴需求日益旺盛；与此同时，云端 AI 服务在数据主权、网络依赖与长期使用成本等方面存在天然短板，本地化部署的大模型凭借数据不出本机、离线可用、成本可控等优势，成为构建隐私友好型智能陪伴系统的可行技术路线。这进一步凸显了本课题的研究价值与实践空间。

1.2 研究目的

本课题旨在设计并实现一个基于本地大模型的智能 AI 陪伴聊天系统，具体目的包括：（1）利用 Ollama 本地化部署方案，实现大模型的私有化运行，保障用户数据隐私并降低使用成本；（2）通过 AI 角色与 AI 精灵双体系设计，为用户提供人格化、个性化的陪伴交互体验；（3）构建长期记忆机制，使 AI 能够持续记住用户并保持角色一致性；（4）实现 Web 端、桌面端与移动端多端覆盖，满足不同场景下的使用需求；（5）围绕系统建立完整的测试体系，确保功能与交付质量。

1.3 研究意义

本课题的研究意义体现在三个方面：在应用层面，系统可为用户提供情感陪伴、娱乐互动与知识问答等多样化服务，缓解现代社会中的孤独感与精神陪伴需求；在技

批注 [4]: 特别注意：论文题目与题目审核表中保持完全一致，包括英文大小写、是否有空格、是否有“的”都要完全相同。

批注 [5]: 开题报告应包括下列主要内容：
1．研究背景及研究的目的和意义；2．国内外在该方向的研究现状及分析；3．主要研究内容；4．研究方案及进度安排，预期达到的目标；5．为完成课题已具备和所需的条件；6．预计研究过程中可能遇到的困难和问题，以及解决的措施；7．主要参考文献。

批注 [6]: **一级节标题（序号为 1.2.3.……，序号后用.不用、）：**首行缩进 2 字符，黑体四号；段前 0.5 倍，段后 0.5 倍；行距：多倍行距 1.25 倍
字母数字的字体为 TimeNewRomans

批注 [7]: **正文内容（下同）：**宋体小 4 号，首行缩进 2 格，段前、段后距为 0；行距：固定值 1.25 倍。
字母数字的字体为 TimeNewRomans

批注 [8]: **二级节标题：**缩进 2 字符，黑体小 4 号；段前 0.5 行，段后 0.5 行；行距：多倍行距 1.25 倍
字母数字的字体为 TimeNewRomans

术层面，课题涉及本地大模型部署、提示词工程、记忆机制、多端架构等关键技术，是对大模型应用工程化的有益探索；在人才培养层面，课题涵盖需求分析、系统设计、编码实现、测试与论文撰写全流程，能够全面锻炼综合工程能力。

2. 国内外在该方向的研究现状及分析

国外方面，OpenAI 推出的 ChatGPT 引领了生成式大模型的发展，其多轮对话与指令遵循能力达到较高水平；Anthropic 推出的 Claude 在长上下文理解与安全性方面表现突出。在陪伴类产品方面，Character.AI 通过角色扮演对话为用户提供情感陪伴，Replika 则聚焦 AI 伴侣场景。在基础研究方面，Vaswani 等人提出的 Transformer 架构奠定了大语言模型的基础，Zhao 等人对大规模语言模型的研究进展进行了系统综述。

国内方面，字节跳动推出豆包、月之暗面推出 Kimi、百度推出文心一言等大模型产品，在中文理解与多模态交互方面各具特色；星野、猫箱等角色扮演类产品在年轻用户中具有较高热度。在本地化部署方面，Ollama、llama.cpp、LM Studio 等开源工具使大模型能够在消费级硬件上离线运行，极大降低了私有化部署门槛，相关研究已应用于智能客服、知识库问答等场景。

综合分析，现有研究存在以下不足：通用大模型助手缺乏稳定人格与长期记忆；角色扮演类产品多依赖云端服务，存在隐私与成本问题；本地化部署研究多面向工具型问答，缺乏与人格化陪伴、社交互动的融合。本课题将本地大模型、AI 角色人格化、记忆机制与多端社交功能相结合，具有一定的创新性与研究价值。

3. 主要研究内容

（1）系统总体架构设计：设计前后端分离、分层清晰的系统架构，采用 Spring Boot 3.2.5 作为后端框架、Vue 3 作为前端框架，结合 MySQL 8 与 Redis 实现数据存储与缓存，通过 RESTful API 与 WebSocket/SSE 实现前后端通信，并支持 Web 端、Electron 桌面端与移动端（响应式网页版）三端复用。

（2）AI 角色与记忆引擎：实现 AI 角色与 AI 精灵双体系的创建、设定与对话管理，包括角色人设提示词构建、上下文管理、角色一致性维持与流式对话输出；设计基于向量检索、重要度评分与时间衰减的长期记忆机制，让 AI 能够持续积累对用户的了解；支持语音识别与语音合成等交互方式，并实现可移动、可交互的 AI 桌面精灵。

（3）社交与管理后台：实现好友、私聊、群聊、兴趣社群、动态发布等社交功能，构建用户与 AI、用户与用户之间的互动生态；实现管理员后台的用户管理、数

批注 [9]: 开题报告里面文中引用的参考文献不用加角标

据池管理、公告管理与 AI 系统管理；建立基于 JWT 的认证授权与 RBAC 权限控制、内容审核与敏感词过滤、未成年保护模式等安全合规机制，并建立单元测试、集成测试与系统测试三层测试体系。

在功能组织上，系统遵循“一端接入、三端协同”的设计思路：Web 端面向完整功能管理与深度对话场景，Electron 桌面端提供沉浸式对话与桌面精灵陪伴体验，移动端网页版满足移动场景下的轻量访问需求；三端共享统一后端服务与数据体系，保证会话、记忆与社交数据的实时一致，其功能分布如图 1 所示。

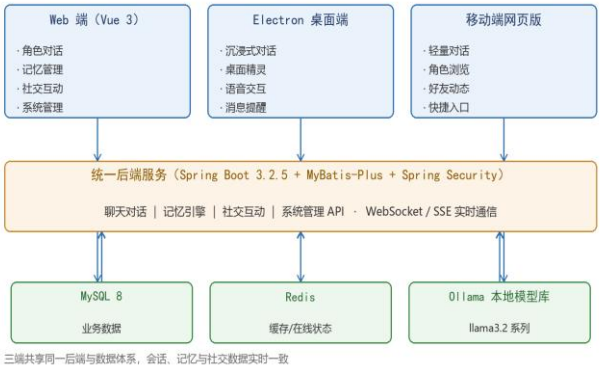


图 1　系统三端功能架构图

4. 研究方案及进度安排，预期达到的目标

4.1 研究方案

本课题采用“需求分析—系统设计—编码实现—测试验证”的工程化流程推进。技术选型上，后端采用 Spring Boot 3.2.5 与 MyBatis-Plus，结合 Spring Security 实现安全控制；前端采用 Vue 3 与 Vite 构建 Web 端与桌面端，并通过响应式适配形成移动端网页版；大模型采用 Ollama 部署 llama3.2 等开源模型，通过 HTTP 接口与 SSE 流式响应接入对话能力；数据层使用 MySQL 8 存储业务数据、Redis 缓存热点数据；WebSocket 用于消息推送与桌面精灵互动。系统总体架构分为表现层（三端界面）、应用层（聊天、记忆、社交、管理等业务模块）、服务层（大模型服务、语音服务、消息服务）与数据层（MySQL、Redis、本地模型库）；大模型接入采用统一模型适配层，支持多模型路由与降级切换；记忆机制采用“对话提取—向量化存储—相关检索—衰减更新”的闭环流程，模拟“这一刻的自己，加上发生的经历、对经历的感受与过去留下的记忆，共同形成下一刻的自己”的灵魂算法思想。

具体而言，系统总体架构自上而下分为表现层、应用层、服务层与数据层四层：表现层由 Web 端、Electron 桌面端与移动端网页版构成，通过 RESTful API 与 WebSocket/SSE 与后端通信；应用层承载聊天对话、AI 角色与 AI 精灵、记忆引擎、社交互动与系统管理等核心业务模块；服务层提供大模型推理、语音识别与合成、消息推送等能力，其中大模型统一适配层支持 Ollama 本地模型的多模型路由与降级切换；数据层以 MySQL 8 存储业务数据、Redis 缓存热点数据，并由本地模型库承载模型文件。系统总体架构如图 2 所示。

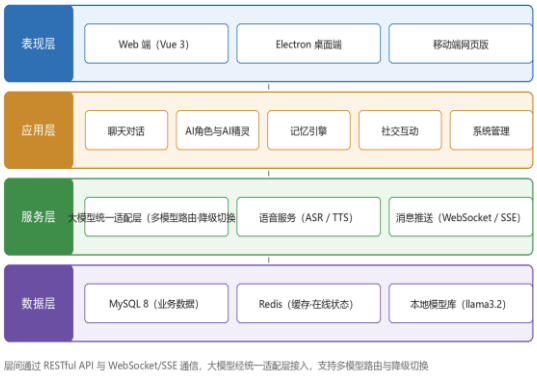


图 2　系统总体架构图

为使 AI 角色具备持续的人格一致性与成长性，系统将“灵魂算法”思想落地为可执行的记忆与人格演化机制：以角色当前状态为基座，叠加每一次对话经历、对经历的感受与理解，并结合长期记忆沉淀，共同演化出下一时刻的自我状态；记忆体系分为短期会话记忆与长期向量记忆两层，通过重要度评分、时间衰减与定期一致性维护，完成记忆的写入、检索与遗忘闭环，其流程如图 3 所示。



图 3　AI 灵魂算法与分层记忆流程图

4.2 进度安排

起讫时间	工作内容
2026 年 9 月~2026 年 10 月	需求分析、文献调研、系统总体设计
2026 年 10 月	开题答辩
2026 年 10 月~2026 年 12 月	系统开发与核心功能实现
2026 年 12 月	中期检查
2026 年 12 月~2027 年 3 月	功能完善、多端联调与系统测试
2027 年 3 月	毕业设计（论文）评审
2027 年 3 月~2027 年 4 月	论文修改与完善
2027 年 4 月	档案提交

4.3 预期达到的目标

（1）完成基于本地大模型的智能 AI 陪伴聊天系统，实现 Web 端、桌面端与移动端三端完整可用；

（2）实现 AI 角色与 AI 精灵双体系，支持人格化对话、语音交互与桌面宠物互动；

（3）实现 AI 长期记忆机制，提供个性化陪伴体验；

（4）实现好友、群聊、兴趣社群等社交功能，构建互动生态；

（5）实现管理员后台与安全合规机制（JWT、RBAC、内容审核、未成年保护）；

（6）建立三层测试体系，自动化测试用例达到 1000 个以上且全部通过，系统稳

批注 [10]: **进度起讫时间安排已固定，填写工作内容即可**

批注 [11]: 表格里面的空白部分要写和自己课题相关内容，其他部分已固定，不要修改或删除

批注 [12]: 此处不代表标题，应使用正文格式

定运行；

5. 为完成课题已具备和所需的条件

（1）已系统掌握 Java 面向对象编程、数据结构与算法、数据库原理等专业知识，具备 Spring Boot、MyBatis-Plus、MySQL、Redis、Vue.js 等主流技术的开发能力；

（2）已具备大语言模型基础理论知识，掌握 Ollama 本地部署与模型调用方法，完成了 llama3.2 等模型的本地运行验证；

（3）已完成系统主体功能开发与初步测试，积累了 Web 端、桌面端、移动端三端联调经验；

（4）具备一台高性能个人电脑（16GB 以上内存），已安装 JDK17、Node.js、MySQL8、Redis、Ollama 等软硬件环境。

6. 预计研究过程中可能遇到的困难和问题，以及解决的措施

6.1 困难及问题

（1）本地大模型受硬件算力限制，模型参数规模与推理速度受限，可能影响对话质量与响应体验；

（2）AI 角色在多轮对话中可能出现人格漂移与记忆混淆，长期记忆的准确提取与更新难度较大；

（3）三端适配复杂度高，移动端网页版存在屏幕适配与浏览器兼容差异，Electron 桌面端存在跨平台兼容问题；

6.2 解决措施

（1）选用量化后的中小规模模型（如 llama3.2 系列），通过提示词优化、多模型路由与异步流式响应提升体验，必要时引入云端模型作为降级方案；

（2）设计分层记忆结构，短期记忆采用会话上下文管理，长期记忆采用向量检索、重要度评分与时间衰减机制，并定期对角色档案进行一致性维护；

7. 主要参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach: Curran Associates Inc., 2017: 5998-6008.

批注 [13]: 此处不代表标题，应使用正文格式

[2] ZHAO W X, ZHOU K, LI J, et al. A survey of large language models[J/OL]. arXiv preprint arXiv:2303.18223, 2023[2026-10-06]. https://arxiv.org/abs/2303.18223.

[3] 赵鑫, 窦志成, 文继荣. 大语言模型时代下的信息检索研究发展趋势[J]. 中国科学基金, 2023, 37(5): 786-792.

[4] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.

[5] 王昊奋, 漆桂林, 陈华钧. 知识图谱: 方法、实践与应用[M]. 北京: 电子工业出版社, 2019.

[6] Ollama. Ollama documentation[EB/OL]. [2026-10-06]. https://ollama.com.

[7] Pivotal Software. Spring Boot reference documentation[EB/OL]. [2026-10-06]. https://docs.spring.io/spring-boot.

[8] Vue.js. Vue.js documentation[EB/OL]. [2026-10-06]. https://cn.vuejs.org.

[9] Redis. Redis documentation[EB/OL]. [2026-10-06]. https://redis.io/docs.

[10] Mozilla 开发者网络. 响应式设计[EB/OL]. [2026-10-08]. https://developer.mozilla.org/zh-CN/docs/Learn/CSS/CSS_layout/Responsive_Design.

[11] Electron. Electron documentation[EB/OL]. [2026-10-06]. https://www.electronjs.org/docs.

[12] 李航. 统计学习方法[M]. 2 版. 北京: 清华大学出版社, 2019.

指导教师评语：

……

……

综上所述，同意开题。

指导教师（签字）		签字时间	2026 年 10 月 11 日

批注 [14]: 参考文献内容：悬挂缩进 1 字符；宋体 5 号，段前 3 磅，段后 0 行；行距：固定值 1.25 倍；参考文献中的标点符号均在英文状态下输入

字母数字的字体为 TimeNewRomans

注意不要在一篇参考文献段落的中间换页。

批注 [15]: 每篇开题报告至少要有 12 个及以上的参考文献，包括 2 篇及以上外文文献，近五年文献占比三分之二以上，以期刊为宜。

参考文献根据撰写规范格式书写，并按顺序编号，即**按文中引用的顺序将参考文献附于文末**。

作者姓名写到第三位，英文状态下逗号分隔“,”，余者写“,等”或“,et al.”。所以有期刊类参考文献（包括外文期刊）要写到页码

批注 [16]: 英文单词中间原则上不允许换行，但细节处可自行判断是否美观来进行细微调整。

批注 [17]: 可打字输入，不少于 150 字。

教师评语应对课题内容进行简单描述，并分析其深度、广度，工作量是否合适，学生对课题的理解是否到位，学生能否在规定时间内完成课题研究。

“同意开题”四个字必须写在评语的末尾。

批注 [18]: 电子版电子签，纸质版手签